## I dati delle automobili

Data Mining CLAMSES - University of Milano-Bicocca

Aldo Solari

## Riferimenti bibliografici

- AS §2.1.1, §2.1.2

I dati delle automobili si riferiscono alle caratteristiche di 203 modelli di automobili importati negli USA nel 1985

I dati originali sono disponibili qui:

ftp://ftp.ics.uci.edu/pub/machine-learning-databases/
autos

Questi dati sono stati elaborati convertendo le unità di misura, eliminando alcune variabili originarie, correggendo alcuni nomi di marche, etc.

Obiettivo: prevedere il consumo di carburante (o, equivalentemente, la distanza percorsa per unità di carburante) in funzione di determinate caratteristiche di un'automobile

- brand : manufacturer (factor, 22 levels), casa produttrice (fattore, 22 livelli) - fuel: type of engine fuel (factor, 2 levels: diesel, gasoline), tipo di alimentazione del motore (fattore, 2 livelli)
- aspiration: type of engine aspiration (factor, 2 levels: standard, turbo), tipo di aspirazione del motore (fattore, 2 livelli)
  - bodystyle: type of body style (factor, 5 levels: hardtop, wagon, sedan, hatchback, convertible), tipo di carrozzeria (fattore, 5 livelli) - drive.wheels: type of drive wheels (factor, 3 levels: 4wd, fwd, rwd), tipo di trazione
  - (fattore, 3 livelli) engine.location: location of engine (factor, 2 levels: front, rear), posizione del motore (fattore, 2 livelli)
  - wheel.base : distance between axes (cm), distanza tra gli assi (cm)
  - length: length (cm), lunghezza (cm) - width : width (cm), larghezza (cm)
    - height: height (cm), altezza (cm)
    - curb.weight: weight (kg), peso (kg)
  - engine size: engine size (l), cilindrata (l)
  - compression.ratio: compression ratio, rapporto di compressione
- HP: horsepower, cavalli motore - peak.rot : number of peak revolutions per minute, numero di giri massimi del motore al
  - minuto
  - city.distance : city distance covered (km/l), percorrenza urbana (km/l)
  - highway.distance : highway distance (km/l), percorrenza extra urbana (km/l) - n.cylinders : number of cylinders, numero di cilindri

I dati delle automobili si riferiscono alle caratteristiche di 203 modelli di automobili importati negli USA nel 1985

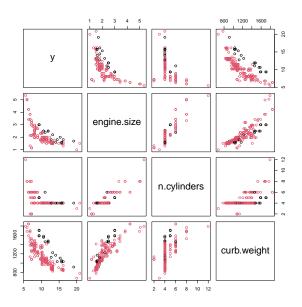
I dati originali sono disponibili qui:

ftp://ftp.ics.uci.edu/pub/machine-learning-databases/
autos

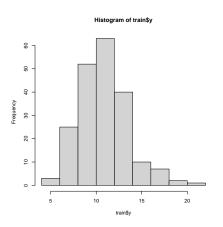
Questi dati sono stati elaborati convertendo le unità di misura, eliminando alcune variabili originarie, correggendo alcuni nomi di marche, etc.

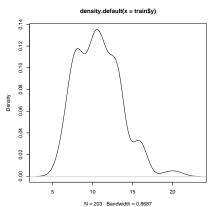
Obiettivo: prevedere il consumo di carburante (o, equivalentemente, la distanza percorsa per unità di carburante) in funzione di determinate caratteristiche di un'automobile

#### Dataset ridotto

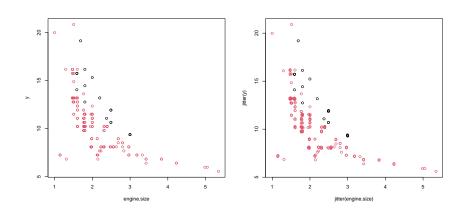


## Istrogramma e stima della densità






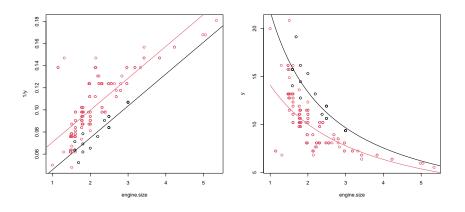
# Diagramma di dispersione (jittered) y $\sim$ engine.size



### Modello 1

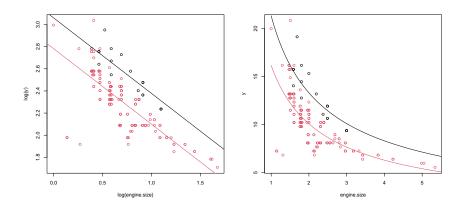


#### Modello 2



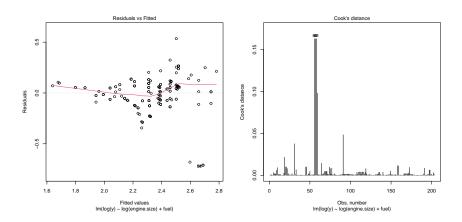
$$1/y = \beta_1 + \beta_2$$
engine.size +  $\beta_3 I$ {fuel = gas} +  $\varepsilon$ 

## Modello 3



$$\log(y) = \beta_1 + \beta_2 \log(\text{engine.size}) + \beta_3 I\{\text{fuel} = \text{gas}\} + \varepsilon$$

#### Bontà di adattamento



```
train[which(cooks.distance(fit3) > .07),]
y engine.size n.cylinders curb.weight fuel
31 20.832 1.5076 4 777.0 gas
154 11.479 1.5076 4 1410.7 gas
```

table(train\$n.cylinders)

2 3 4 5 6 8 12 4 1 157 11 24 5 1

## Modello 3 (aggiornato)

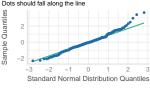
$$\log(y) = \beta_1 + \beta_2 \log(\text{engine.size}) + \beta_3 I\{\text{fuel} = \text{gas}\} + \beta_4 \log(\text{curb.weight}) + \beta_5 I\{\text{n.cylinders} = 2\} + \varepsilon$$

#### Posterior Predictive Check Linearity Model-predicted lines should resemble observed data li Reference line should be flat and horizontal 0.15 0.3 0.2 Residuals Density 0.10 0.1 -0.1-0.2 20 2.0 log(y) Fitted values - Observed data - Model-predicted data Homogeneity of Variance Influential Observations Reference line should be flat and horizontal Points should be inside the contour lines |Std. residuals| Std. Residuals 1.5 1.0 -20 0.00 0.10 0.15 0.20 Fitted values Leverage (h<sub>ii</sub>)

#### Collinearity

#### Hir collinearity (VIF) may inflate parameter uncertainty. Dots should fall along the line Factor (VIF, log-scale 10 Variance Inflation 5 3 2 fuel(n.cylindersocace)rb.wkzighthgine.size Low (< 5) Moderate (< 10)</p>

#### Normality of Residuals



```
fit1 = update(fit1, . ~ . + log(curb.weight)
+ I(n.cylinders==2), train)
mean(resid(fit1)^2)
[1] 1.07706
fit2 = update(fit2, . ~ . + log(curb.weight)
+ I(n.cylinders==2), train)
mean((train$y - 1/fitted(fit2))^2)
[1] 1.143411
fit3 = update(fit3, . ~ . + log(curb.weight)
+ I(n.cylinders==2), train)
mean((train$y - exp(fitted(fit3)))^2)
```

[1] 1.016788